

Hackapizza

Community Edition




Bytebusters


Stefano Iannicelli
Ettore Caputo

Hackapizza

6 marzo, 2025



Panoramica della soluzione



Main idea

Data preparation

Architecture

Keyword Extractor

Tech Expert

Distance Expert

Menu Header Expert

Menu Corpus Expert

Criticità e possibili miglioramenti

Main idea

Estrazione delle keyword,
riformulazione con LLM specializzati,
ricerca mirata.

Certainty


Desideravamo garantire che i chunk di testo impiegati nel processo di RAG fossero esclusivamente pertinenti alla domanda.

Token efficiency

Sfruttando la certezza sui chunk, abbiamo rimosso l'utilizzo del LLM durante l'estrazione del nome dei piatti dai chunk. Risparmiando sui token di contesto.

Task distribution

Il processo di generazione della risposta è articolato in più fasi, ciascuna gestita da diversi LLM "specializzati".



Data preparation

Trasformazione e formattazione



1

Split dei file menu

Abbiamo suddiviso ogni file menù in:

- header (la porzione che precede la lista dei piatti)
- un chunk per ogni piatto contenuto nel menù.

2

Etichettatura dei piatti

All'interno dei file, i nomi dei piatti sono stati racchiusi tra i tag `<dish>` `</dish>`. Questo ne ha reso più semplice l'estrazione dal contesto.

3


Tabelle e altro

Le tabelle sono state ricostruite poiché la conversione da PDF a TXT le aveva corrotte. I numeri romani sono stati trasformati mediante l'uso di una regex.

Architecture



- Dalla domanda vengono estratte tutte le keywords.
- Le keywords vengono utilizzate dai vari esperti.
- Il Tech expert ottiene informazioni sulle tecniche presenti nel Codice di Galattico.
- Il Distance expert ottiene informazioni sulle distanze tra pianeti.
- Il Menu header expert ottiene informazioni dai soli header dei menu.
- Il Menu corpus expert ottiene informazioni dai piatti contenuti nei menu.
- La risposta viene estratta dal contesto fornito dal Menu corpus expert.



Keyword extractor



Prompt ad un LLM

Viene chiesto ad un LLM di estrarre le keyword dalla domanda, categorizzandole come segue:

```
{  
  "licenze chef": [ ... ],  
  "licenze tech": [ ... ],  
  "pianeti": [ ... ],  
  "ingredienti": [ ... ],  
  "tecniche galattiche": [ ... ],  
  "tecniche comuni": [ ... ],  
  "chef": [ ... ],  
  "ristoranti": [ ... ]  
}
```



Tech expert



Attivazione

Questo esperto si attiva solo quando nelle keyword estratte ci sono le “licenze tech” o “tecniche comuni”.



Estrazione delle tecniche

Quando utilizzato, il tech expert cerca le tecniche presenti nel Codice Galattico, che soddisfano la query sulla base delle keywords di attivazione.

Per fare ciò diamo in input il Codice Galattico come contesto al LLM.

Quindi, viene riformulata la query sulla base delle nuove informazioni ottenute, aggiungendo le tecniche estratte dal Codice Galattico.

Esempio

Quali piatti utilizzano tecniche di congelamento non contengono Teste di Idra?

Quali piatti utilizzano il “Congelamento Quantico” e il “Congelamento Supersonico” ma non contengono Teste di Idra?




Distance expert



Attivazione

Questo esperto si attiva solo se nella domanda è presente "anni luce".



Estrazione dei pianeti

Quando utilizzato, il distance expert cerca i pianeti che soddisfano la query.

Per fare ciò diamo in input il file delle distanze nel contesto del LLM.

Quindi, viene riformulata la query sulla base delle nuove informazioni ottenute, aggiungendo i pianeti che rispettano la distanza richiesta.

Esempio

Quali piatti preparati in ristoranti distanti 300 anni luce da Namecc contengono Teste di Idra?

Quali piatti preparati su Asgard e Pandora contengono teste di idra?



Header menu expert



Attivazione

Questo esperto si attiva solo se sono presenti keyword di:

- "ristoranti"
- "chef"
- "pianeti"
- "licenze chef"

Poichè nell'header sono presenti al più queste informazioni.



Estrazione degli id dei documenti

Quando utilizzato, questo nodo trova gli id dei menu che rispettano la query.

Per fare ciò chiediamo ad un LLM di riformulare la query in una query booleana con solo le keyword di attivazione nodo.

Una volta che il modello ha formulato la query booleana eseguiamo una ricerca su tutti gli header dei menu e ritorniamo solo gli id che rispettano la query booleana.

Esempio

Quali piatti preparati in ristoranti sul pianeta Pandora dallo chef Cannavacciuolo contengono Lumache Lucenti?

Keyword da usare per formare la query booleana: ["Pandora", "Cannavacciuolo"]

Output LLM: ("Pandora" AND "Cannavacciuolo")

Output node: [13, 16, 7] 13,16,7 sono id di ristoranti tale che il loro header rispetta la query booleana

Corpus menu expert




Attivazione

Questo esperto si attiva solo se sono presenti keyword di:

- “tecniche galattiche”
- “ingredienti”

Arrivati a questo nodo, se i precenti hanno funzionato esiste almeno una keyword di “tecniche galattiche” o “ingredienti”



Estrazione degli id dei documenti

Quando utilizzato, questo nodo trova i chunk di testo che contengono i nomi dei piatti che rispondono alla query.

Per fare ciò chiediamo ad un LLM di riformulare la query in una query booleana con solo le keyword di attivazione nodo.

Una volta che il modello ha formulato la query booleana eseguiamo una ricerca su tutti i corpus dei menu e ritorniamo solo i chunk che rispettano la query booleana.

Esempio

Quali piatti preparati tramite la tecnica di Congelamento Quantico utilizzano Spore Radioattive ma non le Alghe Fritte?

Keyword da usare per formare la query booleana: [“Congelamento Quantico”, “Spore Radioattive”, “Alghe Fritte”]

Output LLM: (“Congelamento Quantico” AND “Spore Radioattive” AND NOT “Alghe Fritte”)

Output node: La lista dei chunk di testo che contengono i piatti richiesti nella domanda iniziale.

Extract answer



Estrazione piatti

Prima di effettuare l'estrazione, viene fatta l'intersezione tra gli id dei ristoranti che hanno soddisfatto le query booleane degli esperti "header" e "corpus".

Vengono quindi estratti, senza l'uso di im llm, tutti i nomi dei piatti presenti nei chunk ottenuti al passo precedente.

Grazie alla fase di etichettatura iniziale, i piatti nel testo sono facilmente estraibili poiché tra i tag <dish><\dish>.



RAG!!! not so much

Poichè sono state utilizzate query booleane abbiamo la certezza che i chunk ritornati dal menu corpus expert siano tutti e solo i chunk che contengono nomi di piatti che rispondono alla domanda iniziale. Per questo motivo non c'è bisogno di usare un LLM per individuare le risposte.



Risultati ottenuti

76.465

Only
Menu Expert

63.5

score

Adding
Distance Expert

66.7

score

Adding
Tech Expert

76.465

score

Analisi

critica della soluzione proposta



Modello booleano rigido

Le query booleane che costruiamo durante il processo sono notoriamente rigide. Errori nei nomi delle keyword non sono ammessi.

Possibile soluzione: ipotizzando di avere a disposizione l'intero set di keyword possibili, si potrebbe utilizzare la distanza di Levenshtein per correggere gli errori e garantire il corretto funzionamento del modello booleano, ricucendo le keyword errate a quella del dizionario con distanza di Levenshtein minima. Inoltre, l'introduzione di un sistema di caching permetterebbe di memorizzare le correzioni più frequenti, mantenendo così performance scalabili anche al crescere del carico

Implementazione del tech expert

Nel tech expert si dà in input all'LLM tutto il Codice Galattico. Un notevole risparmio di token si otterrebbe costruendo un sistema di retrieval, simile a quello del corpus expert, che restituisca solo i chunk desiderati.

Ricerca booleana

Il parsing della query booleana è stato eseguito manualmente e la ricerca avviene in modo estensivo sui chunk; poiché i documenti sono pochi il sistema risulta comunque molto veloce, ma con un numero elevato di documenti e query con molte clausole in OR potrebbe diventare lento

Soluzione

Introdurre un sistema di indicizzazione che consenta di pre-strutturare i dati, rendendo la fase di ricerca molto più efficiente e scalabile, come Elasticsearch o Pyserini.

Grazie



stefano.iannicelli362@gmail.com

ettore.caputo27@gmail.com

